

· INICIO ·

CASO ACADÉMICO · MACHINE LEARNING SUPERVISADO

Predicción de diagnóstico oncológico con redes neuronales.

50 001 pacientes · 6 fuentes clínicas en Azure · 4 modelos clásicos + 1 MLP.

Alejandro Barreche Ruiz

GRADO EN INGENIERÍA MATEMÁTICA · JACINTO VELASCO

CURSO 2025-2026

I · PLANTEAMIENTO

¿Podemos anticipar un diagnóstico oncológico a partir de datos rutinarios?

Y, sobre todo, ¿con qué fiabilidad?

50 001_{pac.}

COHORTE · AZURE SQL

19,3%

PREVALENCIA · CLASE POSITIVA

6 → 1

FUENTES UNIDAS POR PACIENTE_ID


5

VARIABLES EXCLUIDAS POR LEAKAGE

II · DATOS Y PIPELINE

Seis fuentes clínicas colapsadas en
un único dataset modelable

con feature engineering anti-leakage por diseño.



FUENTE 01 · BIOQUÍMICOS

Analíticas

glucosa · colesterol

trigliceridos · hemoglobina

leucocitos · plaquetas · creatinina

TRATAMIENTO

StandardScaler

UMBRALES CLÍNICOS

+ binarias

FUENTE 02 · GENÉTICOS

Mutaciones germinales

BRCA1 · TP53 · KRAS

EGFR · PIK3CA · ALK · BRAF

+ carga mutacional agregada

LIFT BRCA1

2,6×

LIFT TP53

2,4×

SEÑAL ALTA

FUENTE 03 · CLÍNICOS + HÁBITOS

Comorbilidades

obesidad · hipertension · diabetes

asma · epoc · enf. cardíaca

fumador · actividad_fisica

LIFT FUMADOR

2,4×

R OBESIDAD

+0,198

FUENTE 04 · SOCIODEM. + ECON.

Perfil del paciente

edad · num_hijos · zona

nivel_educativo · ingresos · estado_civil

tipo_seguro · distancia_hospital_km

EXCLUIDAS

5 vars

MOTIVO

post-dx

III · COMPARATIVA

Cinco modelos sobre el mismo split.
Empatan en AUC, pero
la MLP es la más conservadora.

MODELO	TIPO	T*	F1	AUC	PREC.	RECALL
XGBoost	CLÁSICO	0,63	0,5827	0,8458	0,5398	0,6330
Logistic Regression	CLÁSICO	0,64	0,5802	0,8487	0,5416	0,6247
MLP · NN ·	RED NEURONAL	0,71	0,5714	0,8439	0,5873	0,5562
Random Forest	CLÁSICO	0,60	0,5722	0,8386	0,5689	0,5754
HistGradientBoosting	CLÁSICO	0,64	0,5696	0,8404	0,5542	0,5858

Métricas sobre test (n = 10 001) · umbral t* tuneado sobre validación · seed 42

LECTURA

Los cinco modelos rondan **AUC ≈ 0,84** — la señal del problema está acotada. La MLP es la que **prioriza precisión**: menos falsos positivos a costa de algo de sensibilidad.

Ranking por AUC-ROC



IV · MODELO FINAL · MLP

Una red densa 300·100·30, entrenada en 18 épocas,
con umbral ajustado sobre validación — nunca sobre test.




Hiperparámetros

48 381 parámetros · 4,78 s de entrenamiento

Optimizador	Adam · lr 1e-3
Pérdida	binary crossentropy
Tamaño de lote	256
Class weight	{0: 0,62 · 1: 2,59}
Early stopping	val_auc · patience 10
Umbral óptimo (val · F1)	0,71


Rendimiento en test

Umbral 0,71 · n = 10 001 pacientes



Matriz de confusión

Test · umbral 0,71



V · CONCLUSIONES Y SIGUIENTES PASOS

La MLP es **comparable al mejor clásico** en AUC, con **menos falsos positivos** — apta para cribado de segunda línea, no como dispositivo médico.

¿CUÁNTO ME FÍO DEL RESULTADO?

0,8439

AUC-ROC en test
Capacidad de ranking honesta, sin leakage.

80 / 20

Split estratificado · seed 42
Test evaluado una única vez al final.

5 / 5

Variables de leakage retiradas
coste_total, dias_hospital, num_ingresos, vive...

t* val

Umbral solo sobre validación
0,71 para F1-max — test intocado.

01

Validar la MLP como cribado de 2º línea

VPP del 58,7 % sobre prevalencia base del 19 % — concentra a los pacientes candidatos a prueba diagnóstica confirmatoria.

02

Iterar sobre la carga mutacional

Las features clínicas derivadas (BRCA1 + TP53 + KRAS, umbrales bioquímicos) dominan importancias — son la palanca de mejora.

03

Replicar con datos reales

El generativo introduce asociaciones por diseño. Antes de uso clínico habría que recalibrar sobre cohorte hospitalaria propia.

04

Monitorizar deriva y umbral

Si la prevalencia o el perfil del paciente cambia, t* se recalcula sobre nuevas particiones de validación, nunca sobre test.

· CIERRE ·

Muchas gracias.

El predictor interactivo queda disponible en la app web del proyecto.