

· INICIO ·

CASO ACADÉMICO · MACHINE LEARNING SUPERVISADO

# Predicción de diagnóstico oncológico con redes neuronales.

50 001 pacientes · 6 fuentes clínicas en Azure · 4 modelos  
clásicos + 1 MLP.

**Alejandro Barreche Ruiz**

GRADO EN INGENIERÍA MATEMÁTICA · JACINTO VELASCO

CURSO 2025-2026

I · PLANTEAMIENTO

# ¿Podemos anticipar un diagnóstico oncológico a partir de datos rutinarios?

Y, sobre todo, ¿con qué fiabilidad?

50 001<sub>pac.</sub>

COHORTE · AZURE SQL

19,3%

PREVALENCIA · CLASE POSITIVA

6 → 1

FUENTES UNIDAS POR PACIENTE\_ID


5

VARIABLES EXCLUIDAS POR LEAKAGE

II · DATOS Y PIPELINE

Seis fuentes clínicas colapsadas en un único dataset modelable,

con feature engineering anti-leakage por diseño · 50 001 pacientes · 0 % missingness.



FUENTE 01 · BIOQUÍMICOS

Analíticas

glucosa · colesterol · triglicéridos  
hemoglobina · leucocitos · plaquetas  
creatinina · + umbrales binarios

TRAT. **StdScaler** R MÁX **+0,151**

FUENTE 02 · GENÉTICOS


Mutaciones germinales

BRCA1 · TP53 · KRAS  
EGFR · PIK3CA · ALK · BRAF  
+ carga mutacional agregada

LIFT BRCA1 **2,6×** LIFT TP53 **2,4×**

Señal lineal con cáncer

Pearson r · 12 features con mayor magnitud · sin leakage



FUENTE 03 · CLÍNICOS + HáBITOS

Comorbilidades

obesidad · hipertensión · diabetes  
asma · epoc · enf. cardíaca  
fumador · actividad\_fisica

LIFT FUMADOR **2,4×** R OBESIDAD **+0,198**

FUENTE 04 · SOCIODEM. + ECON.

Perfil del paciente

edad · num\_hijos · zona  
educación · ingresos · estado civil  
tipo\_seguro · distancia\_hospital\_km

EXCLUIDAS **5 vars** MOTIVO **post-dx**

COHORTE

**50 001** pacientes

Una fila por paciente\_id · sin huérfanos.

DESBALANCE

**1:4,18**



9 644 positivos · 19,3 % prevalencia · gestionado con class\_weight.

III · COMPARATIVA

Cinco modelos sobre el mismo split — empatan en AUC, la MLP es la más conservadora.

Test n = 10 001 · umbral t\* tuneado sobre validación · semilla 42.


| MODELO               | TIPO         | T*   | F1     | AUC    | PREC.  | RECALL |
|----------------------|--------------|------|--------|--------|--------|--------|
| XGBoost              | CLÁSICO      | 0,63 | 0,5827 | 0,8458 | 0,5398 | 0,6330 |
| Logistic Regression  | CLÁSICO      | 0,64 | 0,5802 | 0,8487 | 0,5416 | 0,6247 |
| MLP · NN ·           | RED NEURONAL | 0,71 | 0,5714 | 0,8439 | 0,5873 | 0,5562 |
| Random Forest        | CLÁSICO      | 0,60 | 0,5722 | 0,8386 | 0,5689 | 0,5754 |
| HistGradientBoosting | CLÁSICO      | 0,64 | 0,5696 | 0,8404 | 0,5542 | 0,5858 |



LECTURA AUC ≈ 0,84 en los cinco modelos — la señal del problema está acotada. La MLP prioriza precisión: VPP 58,7 % frente al 54,2 % del XGBoost, a cambio de algo de sensibilidad.


IV · MODELO FINAL · MLP

Una red densa 300·100·30 entrenada en 18 épocas,  
con umbral ajustado sobre validación — nunca sobre test · 48 381 parámetros · 4,78 s.



Matriz de confusión

Test · n = 10 001 · umbral 0,71



Hiperparámetros clave

|               |           |            |           |                      |             |
|---------------|-----------|------------|-----------|----------------------|-------------|
| Learning rate | 1e-3      | Batch size | 256       | Class weight         | 0,62 / 2,59 |
| Patience      | 10 épocas | Init       | he_normal | Umbral t* (val · F1) | 0,71        |

F1 POSITIVA

0,5714

AUC-ROC

0,8439

PRECISIÓN · VPP

0,5873

SENSIBILIDAD

0,5562



V · CONCLUSIONES Y SIGUIENTES PASOS

Un modelo validado, una recomendación accionable para el comité.

Apta como cribado de segunda línea — nunca como dispositivo médico.

PLAN OPERATIVO · PRÓXIMAS ITERACIONES

- 01

Desplegar como cribado de 2ª línea

VPP 58,7 % sobre prevalencia base 19,3 % — la MLP triplica la densidad de positivos en la cola que envía a prueba confirmatoria.
- 02

Iterar sobre la carga mutacional

Las features clínicas derivadas ( `n_mutaciones_alto_riesgo` , umbrales bioquímicos) dominan importancias.
- 03

Replicar con datos reales antes de uso clínico

La cohorte es generativa simulada — recalibrar y reevaluar sobre cohorte hospitalaria propia antes de cualquier despliegue.
- 04

Monitorizar deriva y reajustar el umbral

Si la prevalencia o el perfil del paciente cambia,  $t^*$  se recalcula sobre nuevas particiones de validación — el test permanece intocado.

¿CUÁNTO ME FÍO DEL RESULTADO?

El modelo cumple las cuatro reglas anti-leakage del proyecto.

0,8439

AUC-ROC TEST

Ranking honesto, sin variables post-diagnóstico. Rango sano de la literatura.

80 / 20

SPLIT ESTRATIFICADO · SEED 42

Test evaluado una única vez al final · scaler/OHE fit solo sobre train.

5 / 5

VARIABLES DE LEAKAGE RETIRADAS

`coste_total` , `dias_hospital` , `num_ingresos` , `coste_farmaco` , `vive` .

$t^*$  val

UMBRAL SOLO SOBRE VALIDACIÓN

F1-max → 0,71 sobre val · test no ha tocado la elección del umbral.

· CIERRE ·

# Muchas gracias.

El predictor interactivo queda disponible en la app web del proyecto.